

Transport Optimal Computationnel

D'après Gabriel Peyré

5 novembre 2025



Table des matières

1 Problème de Monge	2
1.1 Formulation de Monge	2
1.1.1 Zoologie de Sous-Problèmes	2
1.2 Formulation de Monge Continue	3
2 Formulation de Kantorovitch	5
2.1 Définition Discrète	5
2.2 Équivalence à Monge	6
3 Métrique de Wasserstein	8
3.1 Formulation continue de Kantorovitch	8
3.2 Propriété Métriques du Transport	8
3.3 Interpolation de McCann	10
4 Gaussiennes et Transport Optimal, Dualité	11
4.1 Dualité pour les mesures discrètes	11
4.2 Dualité pour des mesures quelconques	11
4.3 c -transformations	12
4.4 Quelques Cas particuliers	13
4.4.1 Cas Euclidien Quadratique	13
4.4.2 Cas Semi-discret	14
4.4.3 Distance 1-Wasserstein	14
5 Transport Optimal Tranché	14
5.1 Définition et propriétés	14
5.2 En pratique	15
6 Modèles de Flot et Diffusion	15
6.1 Transport optimal dynamique	15
6.2 Couplage de Flot	17

7 Barycentres et Lois Multimarginales	17
8 Barycentre de Sinkhorn	17

Résumé

<mailto:gabriel.peyre@ens.fr> Notes de cours sur <https://arxiv.org/abs/2505.06589> Syllabus : <https://docs.google.com/document/u/0/d/1JlDpcS0tkzX8CSgH1Uf13ZHQRWu650EtNLrycT39dxk/mobilebasic>

Introduction

L'une des motivations principales du cours est de comparer, en apprentissage statistique, des données sous formes de distributions de probabilités, souvent discrètes (nuages de points). On peut penser au transport optimal comme de l'apprentissage non-supervisé : comment associer une distribution de probabilité paramétrique α_θ à une probabilité observée β sur un groupe de points. Dans ce cours, les lettres grecques sont réservées aux distributions de probabilités et les lettres latines aux points. Pour ce faire, on va faire une association de densité $\min_\theta D(\alpha_\theta, \beta)$ qui prend en compte une métrique d . L'idée étant d'utiliser la métrique d pour définir la métrique D , en utilisant la structure de l'espace sous-jacent pour les données. Il faut voir le transport optimal comme un mécanisme d'élévation de l'espace des données vers un espace de probabilité, de sorte que $D = d$ lorsqu'on considère des diracs.

1 Problème de Monge

1.1 Formulation de Monge

Le problème est a été défini pour le but militaire de construire des murs avec des sacs de sables déplacés par des soldats, par Gaspard MONGE, dans un papier à l'académie des sciences.

Commençons par un exemple : si on part d'un ensemble de 3 points x_1, \dots, x_3 et qu'on veut atteindre y_1, \dots, y_3 , quelle est la manière optimale de donner une bijection dont le coût du déplacement est minimal ? On cherche $T : x_i \rightarrow y_{\sigma(i)}$ pour $\sigma \in \mathfrak{S}_3$.

Définition 1.1 Le problème de Monge est le problème d'optimisation suivant :

$$M = \min_{\sigma \in \mathfrak{S}_n} \sum_{i=1}^n C_{i,\sigma(i)} \quad (\text{Monge})$$

où $C \in \mathbb{R}^{n \times n}$. On dit que M est l'assignation optimale.

En général, on définit $C_{i,j} = c(x_i, y_j)$, et c sera généralement la distance géodésique sur une variété, ou une puissance de la norme p sur \mathbb{R}^d . Il n'y a pas besoin de supposer que x et y appartiennent aux mêmes espaces \mathcal{X} et \mathcal{Y} .

Il est clair que le problème de Monge est combinatoirement complexe, puisque $|\mathfrak{S}_n| = n!$. Monge, historiquement, a proposé des liens avec l'optique. L'académie des sciences a proposé un prix à celui qui réussirait à proposer une solution (entendre de nos jours, algorithme polynomial pour la réponse). Aujourd'hui, nous avons un algorithme en $\mathcal{O}(n^3)$, qui est optimal dans le pire cas.

1.1.1 Zoologie de Sous-Problèmes

Dans cette section, on va s'intéresser à quelques sous-problèmes spécifiques, dont le résultat est calculable.

Cas 1-D Ici, on suppose que $\mathcal{X} = \mathcal{Y} = \mathbb{R}$, et que $c(x, y) = h(x - y)$ pour h convexe. En général, on aura $c(x, y) = |x - y|^p$ avec $p \geq 1$. Monge avait étudié le cas $p = 1$ qui est de loin le plus difficile.

Dans ce cas, la solution est l'arrangement croissant : l'application T définie ci-dessus est croissante. On trie les points de gauche à droite et on assigne le plus petit x_i au plus petit y_i et ainsi de suite :

Théorème 1.1 Dans le cas 1-D, si M vérifie :

$$x_i < x_j \Rightarrow y_{M(i)} < y_{M(j)}$$

alors M est une solution de (Monge).

Démonstration. Si la propriété n'est pas vérifiée, alors il existe (i, i') tels que $(x_i - x_{i'})(y_{\sigma(i)} - y_{\sigma(i')}) < 0$ et en composant σ par la transposition $\tau_{i,i'}$ on obtient :

$$h(x_i - y_{\tau(\sigma(i))}) + h(x_{i'} - y_{\tau(\sigma(i'))}) < h(x_i - y_{\sigma(i)}) + h(x_{i'} - y_{\sigma(i')})$$

par convexité de h . ■

Corollaire 1.1 Dans ce cas, on a une complexité en $\mathcal{O}(n \log n)$, en utilisant un algorithme de tri.

R Dans le cas où h est strictement convexe, tous les arrangements optimaux sont croissants, et donc on a l'unicité de la solution M dans le cas où tous les points sont distincts.

Ce cas intervient notamment dans le cas où par exemple on veut comparer deux groupes de niveaux, ou l'égalisation en niveaux de gris de deux histogrammes de luminance (balance des blancs).

L'algorithme ne se généralise pas en deux dimensions, puisque les trajectoires ne peuvent pas se recouper pour un arrangement optimal (par l'inégalité du parallélogramme) mais que cette propriété n'implique pas l'optimalité de la solution. Pire, il peut exister un nombre exponentiel de solution non-optimales dans ce cas.

Couplage Dans le cas où on peut modéliser le problème par un problème de couplage de graphes, on peut utiliser l'algorithme hongrois pour obtenir une solution en $\mathcal{O}(n^3)$.

1.2 Formulation de Monge Continue

Ici, on va s'intéresser à des mesures boréliennes $\alpha \in \mathcal{M}(\mathcal{X}), \beta \in \mathcal{M}(\mathcal{Y})$, pour \mathcal{X}, \mathcal{Y} des espaces métriques. Pour des questions de facilité, on supposera \mathcal{X}, \mathcal{Y} compacts, et pour l'optimisation on les supposera de plus complets, généralement des parties de \mathbb{R}^d . Lorsqu'on aura besoin de retirer l'hypothèse de compacité, on ne demandera de \mathcal{X} et \mathcal{Y} que d'être des espaces polonais. On suppose de plus que α et β sont des mesures de probabilité (positives et de somme 1). On notera l'espace de mesures de probabilité $\mathcal{M}_+^1(\mathcal{X}) = \mathcal{P}(\mathcal{X})$.

Théorème 1.2 — Riesz-Markov Si \mathcal{X} est un espace polonais, et $\mathcal{C}_c(\mathcal{X})$ est l'ensemble des fonctions continues à support compact sur \mathcal{X} muni de la norme $\|\cdot\|_\infty$:

$$\mathcal{M}(\mathcal{X}) = (\mathcal{C}_c(\mathcal{X}))^\circ$$

Démonstration. On utilise pour identification le produit scalaire : $\langle f, \alpha \rangle = \int f d\alpha$. ■

C'est une généralisation du Théorème de Riesz sur un espace de Hilbert. Quelques exemples :

Discrète $\alpha = \sum a_i \delta_{x_i}$ où $a \in \Delta_n$. On appellera souvent le vecteur a l'histogramme, et le vecteur (δ) le nuage de points. Par linéarité, on a :

$$\int f d \left[\sum a_i \delta_{x_i} \right] = \sum a_i f(x_i)$$

Continue/À densité Si $\alpha = \rho_\alpha \beta$ a densité ρ_α par rapport à β :

$$\int f(x) d\alpha(x) = \int f(x)\rho_\alpha(x) d\beta(x)$$

C'est-à-dire : $\langle \cdot, \alpha \rangle = \langle \cdot \times \rho_\alpha, \beta \rangle$. On notera ceci $\alpha << \beta$.

Le produit scalaire défini ci-dessus induit une norme duale dite norme de variation totale :

$$\|\alpha\|_* = \|\alpha\|_{TV} = \sup_{\|f\|_\infty \leq 1} \langle f, \alpha \rangle$$

Proposition 1.1 Pour $\alpha, \beta \in \mathcal{M}(\mathcal{X})$:

$$\|\alpha - \beta\|_{TV} = |\alpha - \beta|(\mathcal{X}) = \int_{\mathcal{X}} d(|\alpha - \beta|)(x)$$

Quelques exemples :

Discrète Si $\alpha = \sum a_i \delta_{x_i}$ et $\beta = \sum b_i \delta_{x_i}$ où $a, b \in \Delta_n$ (ici, on suppose que les nuages de points sont égaux, mais pas que les a_i, b_i sont non nuls) :

$$\|\alpha - \beta\|_{TV} = \sum_i |x_i - y_i|$$

Continue/Denses Si $\alpha = \rho_\alpha \mathcal{L}$ et $\beta = \rho_\beta \mathcal{L}$:

$$\|\alpha - \beta\|_{TV} = \int |\rho_\alpha - \rho_\beta| d\mathcal{L}$$

Mesures Singulières Si $\alpha = 0$ quand $\beta \neq 0$ et réciproquement, $\|\alpha - \beta\|_{TV} = 2$

Définition 1.2 — Push-Forward. Si on a une application de transport $T : \mathcal{X} \rightarrow \mathcal{Y}$, on peut définir une application $T_\sharp : \mathbb{P}(\mathcal{X}) \rightarrow \mathbb{P}(\mathcal{Y})$ définie par :

1. $T_\sharp \delta_x = \delta_{T(x)}$;
2. T_\sharp est linéaire.

De manière équivalente : $\beta = T_\sharp \alpha$ qui vérifie $\beta(B) = \alpha(T^{-1}(B))$.

Proposition 1.2 Si $\beta = T_\sharp \alpha$, on a :

$$\int g d\beta = \int g \circ T d\alpha, \text{i.e. } \mathbb{E}(g(Y)) = \mathbb{E}(g(T(X)))$$

pour $Y = T(X) \tilde{\beta}$ un vecteur aléatoire.

On peut alors réécrire le problème de Monge dans le cas continu :

Définition 1.3 Si $\alpha \in \mathbb{P}(\mathcal{X}), \beta \in \mathbb{P}(\mathcal{Y})$, et c est une fonction de coût :

$$M = \inf_{T: \mathcal{X} \rightarrow \mathcal{Y}} \left\{ \int c(x, T(x)) d\alpha(x) \mid T_\sharp \alpha = \beta \right\} \quad (\text{Monge})$$

Proposition 1.3 Dans le cas discret : $T_\sharp \alpha = \beta \Leftrightarrow \exists \sigma \in \mathfrak{S}_n, T(x_i) = y_{\sigma(i)}$.

Théorème 1.3 Si α a une densité par rapport à β , alors il existe T telle que $T_\sharp \alpha = \beta$.

R Dans le cas discret, cela revient à dire que $|supp(\alpha)| \geq |supp(\beta)|$. Attention, cette application T n'est pas unique !

Théorème 1.4 — Brenier, 1991 Si $\mathcal{X} = \mathcal{Y} = \mathbb{R}^d$ et $c(x, y) = \|x - y\|^2$ (généralisé à une distance géodésique mis à la puissance $1 < p < +\infty$) et si α a une densité par rapport à la mesure de Lebesgue (ou au moins ne donne pas de mesure aux espaces de dimension $< d$) alors il y a un unique transport optimal T solution de (Monge) et T est caractérisé par $T = \nabla \varphi$ où φ est convexe (et ∇ est le gradient riemannien). Il y a un unique $\nabla \varphi$ où φ est convexe et $(\nabla \varphi)_\sharp \alpha = \beta$, c'est le transport optimal.

Corollaire 1.2 Les gradients des fonctions convexes \mathcal{G} sont des transports optimaux.

Proposition 1.4 Pour $T \in \mathcal{G}$, $\langle Tx - Ty, x - y \rangle \geq 0$, les gradients de fonctions convexes sont dans l'ensemble \mathcal{H} des fonctions croissantes.

Dans le cas $\mathcal{X} = \mathcal{Y} = \mathbb{R}$, on a même $\mathcal{G} = \mathcal{H}$. En plus grande dimension, $T(x) = Rx$ où R est une petite rotation n'est pas un gradient mais est croissante. Il est possible que φ ne soit pas différentiable, mais on peut montrer que φ va être différentiable presque partout, et donc nos équations sont à entendre comme des égalités à ensemble de mesure nulle près.

Proposition 1.5 $T(x) = Ax$ est un gradient si et seulement si A est symétrique. $T \in \mathcal{G}$ si et seulement si A est définie positive.

Définition 1.4 La 2-distance de Wasserstein est définie par :

$$W_2^2(\alpha, \beta) = \inf_{T_\sharp \alpha = \beta} \int \|x - Tx\|^2 \, d\alpha(x)$$

Quelques exemples avec les gaussiennes :

Cas 1D Ici, on suppose $\alpha = \mathcal{N}(m_\alpha, \sigma_\alpha^2)$, $\beta = \mathcal{N}(m_\beta, \sigma_\beta^2)$. En prenant $T(x) = \frac{\sigma_\beta}{\sigma_\alpha}(x - m_\alpha) + m_\beta$, on vérifie bien que $T_\sharp \alpha = \beta$ et en primitivant T , on vérifie bien que c'est le gradient (la dérivée) d'une fonction convexe et c'est donc bien un transport optimal. Le coût du transport est :

$$W_2^2(\alpha, \beta) = \|m_\alpha - m_\beta\|^2 + \|\sigma_\alpha - \sigma_\beta\|$$

Cas d -Dimensionnel Ici, $\alpha = \mathcal{N}(m_\alpha, \Sigma_\alpha)$ et $\beta = \mathcal{N}(m_\beta, \Sigma_\beta)$ où $\Sigma_\alpha = \mathbb{E}((X - m_\alpha)^t(X - m_\alpha))$ est une matrice définie positive. On suppose que $\Sigma_\alpha > 0$. On prend alors $T(x) = A(x - m_\alpha) + m_\beta$ où $A\Sigma_\alpha^t A = \Sigma_\beta$ pour trouver le transport optimal. Cette équation (dite de Riccati) a une solution symétrique définie positive. On a de plus :

$$W_2^2(\alpha, \beta) = \|m_\alpha - m_\beta\|^2 + \mathcal{B}^2(\Sigma_\alpha, \Sigma_\beta)$$

où \mathcal{B} est la distance de Bures définie par :

$$\mathcal{B}(A, B) = \text{Tr}(A + B - 2(A^{1/2}BA^{1/2})^{1/2})$$

2 Formulation de Kantorovitch

2.1 Définition Discrète

La formulation de Kantorovitch est une relaxation convexe de la formulation de Monge. Il a obtenu un prix Nobel d'économie pour ceci. Ici, on se limite au cas discret $\alpha = \sum_n \alpha_i \delta_{x_i}$ et $\beta = \sum_m b_j \delta_{y_j}$.

Définition 2.1 Un *couplage* ou un *plan* est une matrice $M \in \mathbb{R}_+^{n \times m}$ qui représente le coût de transport de x_i à y_j et telle que :

$$\sum_j P_{i,j} = a_i \wedge \sum_i P_{i,j} = b_j$$

R C'est la même notion que celle de couplage en probabilité : un vecteur aléatoire sur l'espace produit.

On remarquera que les équations définissant un plan peuvent se mettre sous la forme :

$$P\mathbf{1}_m = a \text{ et } {}^t P\mathbf{1}_n = b$$

On autorise ainsi la division de masse, les problèmes de Kantorovitch devenant des problèmes sur des graphes bipartis.

Définition 2.2 Le polytope des couplages entre α et β est l'ensemble des plans entre α et β :

$$\text{Couplages}(\alpha, \beta) = \{P \in \mathbb{R}_+^{n \times m} \mid P_{i,j} \geq 0, P\mathbf{1}_m = a \text{ et } {}^t P\mathbf{1}_n = b\}$$

Kantorovitch avait fait l'hypothèse très forte que l'économie est linéaire.

Définition 2.3 Le *problème de Kantorovitch* est le problème d'optimisation suivant :

$$P = \operatorname{argmin}_P \{\langle C, P \rangle \mid P \in \text{Couplages}(\alpha, \beta)\} \quad (\text{Kantorovitch})$$

où $C \in \mathbb{R}^{n \times m}$ est une matrice de coût. On dit que P est le plan optimal.

C'est un problème de programmation linéaire. En général la méthode du simplexe n'est pas polynomial, mais il existe un type de simplex pour lequel elle l'est, et c'est en $\mathcal{O}((n^3m + m^3n) \log(mn))$

Proposition 2.1 Il existe toujours une solution, et il existe toujours une solution dite *éparse*, telle que :

$$|\{(i, j) \mid P_{i,j} \neq 0\}| \leq n + m - 1$$

Démonstration. La preuve d'existence vient du fait que l'ensemble des couplages est un compact non vide (car $P = a^t b$ est un couplage dit *indépendant*). ■

Le cas générique est de plus unique, c'est-à-dire que si C, α, β n'a pas une unique solution, en ajoutant du bruit on retrouve une solution optimale.

2.2 Équivalence à Monge

On s'intéresse ensuite aux matrices de permutation P_n , dans le cas $n = m$. On cherche à résoudre le problème non-convexe $\min_{P \in P_n} \langle C, P \rangle$. Clairement, si \mathcal{B}_n est l'ensemble convexe des matrices bistochastiques (l'ensemble des couplages !) :

$$\min_{P \in \mathcal{B}_n} \langle C, P \rangle \leq \min_{P \in P_n} \langle C, P \rangle$$

Définition 2.4 L'ensemble des points extrême d'un convexe C est :

$$\text{Extr}(C) = \left\{ P \mid \forall (Q, R) \in C^2, P = \frac{Q + R}{2} \Rightarrow Q = R \right\}$$

Théorème 2.1 Si C est compact, $\text{Extr}(C) \neq \emptyset$.

Théorème 2.2 — KRAIN-MILLMAN Si C est un compact convexe, alors $C = \text{Hull}(\text{Extr}(C))$.

Proposition 2.2 Si C est compact :

$$\text{Extr}(C) \cap (\arg\min_{P \in C} \langle C, P \rangle) \neq \emptyset$$

Démonstration. En notant que l'ensemble de droite est convexe et compact, on trouve $\text{Extr}(S) \neq \emptyset$ et que $\text{Extr}(S) \subseteq \text{Extr}(C)$. ■

Théorème 2.3 — Birkhoff - von Neumann On a $\text{Extr}(\mathcal{B}_n) = P_n$

Démonstration. On montre d'abord $P_n \subset \text{Extr}(\mathcal{B}_n)$. Cela découle de $\text{Extr}([0, 1]) = \{0, 1\}$. Si $P \in P_n$, est telle que $P = (Q + R)/2$ avec $Q_{i,j}, R_{i,j} \in [0, 1]$, puisque $P_{i,j} \in \{0, 1\}$ alors nécessairement $Q_{i,j} = R_{i,j} \in \{0, 1\}$.

Montrons maintenant $\text{Extr}(\mathcal{B}_n) \subset P_n$ en montrant que $P_n^c \subset \text{Extr}(\mathcal{B}_n)^c$ avec le complémentaire considéré dans \mathcal{B}_n . Choisir $P \in \mathcal{B}_n \setminus P_n$ revient à choisir $P = (Q + R)/2$ où Q, R sont des matrices bistrochastiques distinctes. P définit un graphe biparti de taille $2n$. Le graphe est composé d'arêtes isolées quand $P_{i,j} = 1$ et d'arêtes connectées quand $0 < P_{i,j} < 1$. Si i est un tel sommet à gauche (j à droite), puisque $\sum_j P_{i,j} = 1$, il y a deux arêtes (i, j_1) et (i, j_2) en sortant (de même, (i_1, j) et (i_2, j) entrant en j). On peut donc toujours extraire un cycle par récurrence de la forme :

$$(i_1, j_1, i_2, j_2, \dots, i_p, j_p), \quad \text{i.e. } i_{p+1} = i_1.$$

On suppose que ce cycle est le plus court de l'ensemble fini de cycle. On a toujours :

$$0 < P_{i_s, j_s}, P_{i_{s+1}, j_s} < 1.$$

Les $(i_s)_s$ et $(j_s)_s$ sont distincts puisque le cycle est le plus court. On pose :

$$\varepsilon = \min_{0 \leq s \leq p} \{P_{i_s, j_s}, P_{j_s, i_{s+1}}, 1 - P_{i_s, j_s}, 1 - P_{j_s, i_{s+1}}\}$$

c'est-à-dire $0 < \varepsilon < 1$. En séparant le graphe en deux ensembles d'arêtes :

$$\mathcal{A} = \{(i_s, j_s)\}_{s=1}^p \quad \text{et} \quad \mathcal{B} = \{(j_s, i_{s+1})\}_{s=1}^p.$$

On pose Q et R telle que :

$$Q_{i,j} = \begin{cases} P_{i,j} & \text{si } (i, j) \notin \mathcal{A} \cup \mathcal{B}, \\ P_{i,j} + \varepsilon/2 & \text{si } (i, j) \in \mathcal{A}, \\ P_{i,j} - \varepsilon/2 & \text{si } (i, j) \in \mathcal{B}, \end{cases} \quad \text{et} \quad R_{i,j} = \begin{cases} P_{i,j} & \text{si } (i, j) \notin \mathcal{A} \cup \mathcal{B}, \\ P_{i,j} - \varepsilon/2 & \text{si } (i, j) \in \mathcal{A}, \\ P_{i,j} + \varepsilon/2 & \text{si } (i, j) \in \mathcal{B}, \end{cases}.$$

Par définition d' ε , on a $0 \leq Q_{i,j}, R_{i,j} \leq 1$. Puisque chaque arête gauche de \mathcal{A} a une arête droite dans \mathcal{B} , (et réciproquement) la contrainte de somme sur les lignes (et sur les colonnes) est maintenue, donc $Q, R \in \mathcal{B}_n$. Finalement, on trouve : $P = (Q + R)/2$. ■

Corollaire 2.1 Pour $m = n$ et $a = b = \mathbb{1}_n$, il existe une solution optimale pour le problème Kantorovitch, qui est une matrice de permutation associée à une permutation optimale pour le problème Monge.

3 Métrique de Wasserstein

3.1 Formulation continue de Kantorovitch

On se place ici dans le cadre continu, où α et β sont des mesures de probabilité arbitraires sur \mathcal{X}, \mathcal{Y} . On notera P_1 et P_2 les projections

Définition 3.1 Un *couplage* entre α et β est une mesure de probabilité $\pi \in \mathcal{M}_+^1(\mathcal{X} \times \mathcal{Y})$ telle que $P_1 \sharp \pi = \alpha$ et $P_2 \sharp \pi = \beta$.
On note $\mathcal{U}(\alpha, \beta)$ l'ensemble des couplages entre α et β .

En prenant α et β discrètes, on vérifie bien qu'on retrouve la formulation de l'Equation Kantorovitch.

R Dans le cas où $\mathcal{U}(\alpha, \beta)$ est non vide, le produit tensoriel $\alpha \otimes \beta$ est un couplage, dit *indépendant*.

Définition 3.2 La formulation de Kantorovitch est le problème d'optimisation suivant :

$$\mathcal{L}_c(\alpha, \beta) = \inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\pi(x, y) = \inf_{(X, Y) \sim (\alpha, \beta)} \mathbb{E}[c(X, Y)] \quad (\text{Kantorovitch})$$

où $c : (\mathcal{X} \times \mathcal{Y}) \rightarrow \mathbb{R}^+$ est la fonction de coût.

Proposition 3.1 On se place dans le cas $\mathcal{X} = \mathcal{Y} = \mathbb{R}^d$, $c(x, y) = \|x - y\|^2$. Si α a densité par rapport à la mesure de Lebesgue, avec $T = \nabla \varphi$ l'application optimale pour Monge, $\pi = (\text{Id}, T) \sharp \alpha$ est l'application optimale pour le problème de Kantorovitch.

3.2 Propriété Métriques du Transport

Ici, on se place dans le cas $\mathcal{X} = \mathcal{Y}$ et on se donne une métrique d sur \mathcal{X} . On supposera $c = d^p$ pour un certain $p \geq 1$.

Définition 3.3 Pour $\alpha, \beta \in \mathcal{P}_p(\mathcal{X})$, on définit la distance p -Wasserstein comme :

$$W_p(\alpha, \beta) = (\mathcal{L}_{d^p}(\alpha, \beta))^{1/p} = \left(\inf_{\pi \in \mathcal{U}(\alpha, \beta)} \int d^p(x, y) d\pi(x, y) \right)^{\frac{1}{p}}$$

R On a une version définie à partir du problème de Monge :

$$\inf_{T \sharp \alpha = \beta} \int d^2(x, T(x)) d\alpha(x)$$

mais c'est seulement une pseudo-distance.

Démonstration. Il reste à prouver que W_p définit bien une distance. Pour ça, on a simplement besoin de la séparation et de l'inégalité triangulaire.

Séparation On a : $W_p(\alpha, \beta) = 0 \Rightarrow \int d(x, y) d\pi^*(x, y) = 0 \Rightarrow d(x, y) = 0$, π^* presque surement. Ceci implique que π^* est supporté sur la diagonale de \mathcal{X}^2 , c'est-à-dire $P_1 \sharp \pi^* = \lambda = P_2 \sharp \pi^*$ et donc $\alpha = \beta$.

Inégalité Triangulaire On ne donne la preuve que dans le cas discret, $\alpha = \sum_i a_i \delta_{x_i}$, $\beta = \sum_j b_j \delta_{y_j}$, $\gamma = \sum_k c_k \delta_{z_k}$.

En prenant $\pi_{\alpha\beta}$ et $\pi_{\beta\gamma}$ des plans optimaux, on pose :

$$S_{ijk} = \frac{\pi_{\alpha\beta}(i, j)\pi_{\beta\gamma}(j, k)}{b_j}$$

si $b_j \neq 0$, 0 sinon. On a alors $\sum_i S_{ijk} = \pi_{\beta\gamma}(j, k)$ et $\sum_k S_{ijk} = \pi_{\alpha\beta}(i, j)$. Les trois marginales de S sont (α, β, γ) . On définit alors :

$$\pi_{\alpha\gamma} = \sum_{i,k} \underbrace{\left(\sum_j S_{ijk} \right)}_{\pi_{\alpha\gamma}(i,k)} \delta_{x_i, z_k}$$

On vérifie aisément que c'est bien un couplage entre α et γ . On a alors :

$$\begin{aligned} W_p(\alpha, \gamma) &\leq \left(\sum_{i,k} \pi_{\alpha\gamma}(i,k) d(x_i, z_k)^p \right)^{1/p} \\ &= \left(\sum_{i,j,k} S_{ijk} d(x_i, z_k)^p \right)^{1/p} \\ &\leq \left(\sum_{i,j,k} S_{ijk} (d(x_i, y_j) + d(y_j, z_k))^p \right)^{1/p} \\ &\leq \left(\sum_{i,j,k} S_{ijk} d(x_i, y_j)^p \right)^{1/p} + \left(\sum_{i,j,k} S_{ijk} d(y_j, z_k)^p \right)^{1/p} \\ &= \left(\sum_{ij} \pi_{\alpha\beta}(i,j) d(x_i, y_j)^p \right)^{1/p} + \left(\sum_{jk} \pi_{\beta\gamma}(j,k) d(y_j, z_k)^p \right)^{1/p} \\ &= W_p(\alpha, \beta) + W_p(\beta, \gamma) \end{aligned}$$

Pour étendre la preuve à des mesures générales, on utilise le lemme de recollage.

■

Cette structure permet de munir l'espace $\mathcal{P}_p(\mathcal{X})$ d'une structure d'espace métrique. Dans la suite, on va supposer que \mathcal{X} est compact, mais les définitions peuvent être étendues à \mathbb{R}^d par exemple.

Proposition 3.2 Si \mathcal{X} est borné, pour $1 \leq p \leq q$, on a :

$$W_p(\alpha, \beta) \leq W_q(\alpha, \beta) \leq (\text{diam } \mathcal{X})^{\frac{q-p}{q}} W_p(\alpha, \beta)^{p/q}$$

Démonstration. En posant $\varphi(s) = s^{q/p}$ (qui est convexe), par l'inégalité de Jensen :

$$W_p(\alpha, \beta)^q \leq \left(\int d(x, y)^p d\pi(x, y) \right)^{q/p} \leq \int d(x, y)^q d\pi(x, y)$$

Donc :

$$W_p(\alpha, \beta) \leq \inf \left(\int d(x, y)^q d\pi(x, y) \right)^{1/q} = W_q$$

La preuve est la même pour l'autre inégalité, en utilisant $d^q \leq (\text{diam } \mathcal{X})^{q-p} d^p$.

■

R La propriété précédente montre que sur un compact, toutes les distances p -Wasserstein définissent la même topologie.

Définition 3.4 Une suite (α_n) converge \star -faiblement vers α , noté $\alpha_n \xrightarrow{\star} \alpha$ dans $\mathcal{M}_1^+(\mathcal{X})$ si pour tout f :

$$\int f d\alpha_n \rightarrow \int f d\alpha$$

R

- Dans le cas où $\alpha_n = \delta_{x_n}$, on a convergence vers $\alpha = \delta_x$ si et seulement $x_n \rightarrow x$.
- La convergence \star -faible est la convergence en loi pour les variables aléatoires.

Définition 3.5 La topologie forte sur $\mathcal{M}_1^+(\mathcal{X})$ est celle définie par la distance de variation totale.

Proposition 3.3 Si on prend d la distance 0-1, alors $W_p^p(\alpha, \beta) = \frac{1}{2} \|\alpha - \beta\|_{TV}$.

Proposition 3.4 Si \mathcal{X} est compact, alors α_n converge \star -faiblement si et seulement si $W_p(\alpha_n, \alpha) \xrightarrow{n \rightarrow +\infty} 0$. W_p métrise donc la convergence \star -faible. Si \mathcal{X} n'est pas compact, la convergence pour W_p équivaut à la convergence \star -faible et à la convergence des p -ème moments.

La convergence des sommes de Riemann est équivalente à la convergence \star -faible de $\frac{1}{n} \sum_k \delta k/n \rightarrow \mathcal{U}_{[0,1]}$.

3.3 Interpolation de McCann

On considère deux mesures de probabilité α, β sur $\mathcal{X} = \mathbb{R}^d$.

Définition 3.6 Pour π un plan optimal entre α et β , et pour $t \in [0, 1]$, on définit :

$$\pi_t = P_t \sharp \pi \text{ où } P_t(x, y) = (1-t)x + ty$$

C'est une homotopie, qu'on appelle *Interpolation de McCann* ou *Interpolation de Déplacement*.

Proposition 3.5 L'interpolation de McCann vérifie :

$$\alpha_t \in \operatorname{argmin}_\rho (1-t) W_2^2(\alpha, \rho) + t W_2^2(\beta, \rho)$$

Proposition 3.6 L'espace $(\mathcal{P}_2(\mathbb{R}^d), W_2)$ est un espace géodésique.

Démonstration. Si T est l'application optimale de Monge pour α, β :

$$\begin{aligned} W_2^2(\alpha_t, \alpha_s) &= \int \| (1-t)x + tT(x) - (1-s)x - sT(x) \|^2 d\alpha(x) \\ &= \int \| (t-s)(T(x) - x) \|^2 d\alpha(x) \\ &= |t-s|^2 W_2(\alpha, \beta) \end{aligned}$$

■

4 Gaussiennes et Transport Optimal, Dualité

4.1 Dualité pour les mesures discrètes

Proposition 4.1 Si $\alpha = \sum a_i \delta_{x_i}$ et $\beta = \sum b_j \delta_{y_j}$, et C est une matrice $n \times m$ de coût, en notant $U(\alpha, \beta)$ l'ensemble des couplages entre α et β :

$$L_c(\alpha, \beta) = \max_{(u, v) \in R(\alpha, \beta)} \langle u, \alpha \rangle + \langle v, \beta \rangle$$

où $R(\alpha, \beta) = \{(u, v) \in \mathbb{R}^n \times \mathbb{R}^m \mid u \oplus v \leq C\}$.

Démonstration. On a $L_c(\alpha, \beta) = \min_{\pi \in U(\alpha, \beta)} \langle c, \pi \rangle$. On introduit donc :

$$\max_{(u, v) \in \mathbb{R}^n \times \mathbb{R}^m} \langle u, a - \pi \mathbf{1}_m \rangle + \langle v + b - {}^t \pi \mathbf{1}_n \rangle = \begin{cases} 0 & \text{si } \pi \in U(\alpha, \beta) \\ +\infty & \text{sinon} \end{cases}$$

On a donc :

$$L_c(\alpha, \beta) = \min_{\pi \geq 0} \max_{(u, v) \in \mathbb{R}^n \times \mathbb{R}^m} L(\pi, u, v)$$

avec :

$$\begin{aligned} L(\pi, u, v) &= \langle c, \pi \rangle + \langle u, \alpha - \pi \mathbf{1}_m \rangle + \langle v + b - {}^t \pi \mathbf{1}_n \rangle \\ &\quad \text{Lagrangien} \end{aligned}$$

Puisque dans le cadre de la programmation linéaire, avoir des solutions suffit pour avoir la dualité forte :

$$\begin{aligned} L_c(\alpha, \beta) &= \max_{u, v} \min_{\pi \geq 0} L(\pi, u, v) \\ &= \max_{u, v} \left(\langle u, \alpha \rangle + \langle v, \beta \rangle + \min_{\pi \geq 0} \langle c, \pi \rangle - \langle u, \pi \mathbf{1}_m \rangle - \langle v, {}^t \pi \mathbf{1}_n \rangle \right) \\ &= \begin{cases} 0 & \text{si } u \oplus v \leq C \\ -\infty & \text{sinon} \end{cases} \end{aligned}$$

Finalement :

$$L_c(\alpha, \beta) = \max_{(u, v) \in R(\alpha, \beta)} \langle u, \alpha \rangle + \langle v, \beta \rangle$$

ce qui conclut la preuve. ■

R

- Si π est optimal, son support est inclus dans $\{(i, j) \mid u_i + v_j = C_{i,j}\}$
- $L_c(\alpha, \beta)$ est convexe en α, β (dual) mais est concave en C .

4.2 Dualité pour des mesures quelconques

Proposition 4.2 Si \mathcal{X}, \mathcal{Y} sont compacts, alors :

$$L_C(\alpha, \beta) = \sup_{(f, g) \in R(C)} \int_{\mathcal{X}} f d\alpha + \int_{\mathcal{Y}} g d\beta$$

où :

$$R(C) = \{(f, g) \in \mathcal{C}(\mathcal{X}) \times \mathcal{C}(\mathcal{Y}) \mid \forall (x, y), f(x) + g(y) \leq C(x, y)\}$$

On dit que f, g sont des *potentiels de Kantorovitch*.

Dans le cas où \mathcal{X} n'est pas compact, on remplace \mathcal{C} par \mathcal{C}_b et le résultat tient.

R

- Si π est optimal, de même, son support est tel que les potentiels sont égaux au coût.
- Dans le cas où α et β on retrouve le résultat discret.

4.3 *c*-transformations

On cherche à résoudre :

$$\max_{f \oplus g \leq c} \int g d\beta, \quad f \text{ fixée}$$

On veut donc prendre g aussi grande que possible en ayant :

$$\begin{aligned} g(y) &\leq c(x, y) - f(x) \\ &\leq \inf_{x \in \mathcal{X}} c(x, y) - f(x) \end{aligned}$$

Définition 4.1 Étant donnée $f : \mathcal{X} \rightarrow \bar{\mathbb{R}}$, sa *c*-transformée est :

$$\begin{aligned} f^c : \quad \mathcal{Y} &\rightarrow \bar{\mathbb{R}} \\ f^c(y) &\mapsto \inf_{x \in \mathcal{X}} c(x, y) - f(x) \end{aligned}$$

La *barre c*-transformée de $g : \mathcal{Y} \rightarrow \bar{R}$ est :

$$g^{\bar{c}}(x) = \inf_{y \in \mathcal{Y}} c(x, y) - g(y)$$

Si c est symétrique, alors $f^c = f^{\bar{c}}$.

R

La transformation $(f, g) \rightarrow (f, f^c)$ remplace les potentiels duals par de meilleurs. De même pour $(f, g) \rightarrow (g^{\bar{c}}, g)$ et $(f, g) \rightarrow (g^{\bar{c}}, f^c)$.

Proposition 4.3 Si c est L -lipschitzienne en y , alors f^c est lipschitzienne.

Démonstration. Exercice. ■

À ce stade, on aurait envie d'itérer à partir de potentiels de base puis d'utiliser les *c*-transformées pour obtenir un meilleur résultat. La proposition ci-dessous montre que malheureusement ceci ne fonctionnera pas.

Proposition 4.4 Si on note $f^{c\bar{c}} = (f^c)^{\bar{c}}$ alors :

1. $f \leq \varphi \Rightarrow f^c \geq \varphi^c$;
2. $f^{c\bar{c}} \geq f$;
3. $g^{\bar{c}c} \geq g$;
4. $f^{c\bar{c}c} = f^c$.

Démonstration. 1. Par définition.

2. On a :

$$\begin{aligned} f^{c\bar{c}} &= \inf_{y \in \mathcal{Y}} \left(c(x, y) - \underbrace{\inf_{x' \in \mathcal{X}} (c(x', y) - f(x'))}_{\leq c(x, y) - f(x)} \right) \\ &\geq \inf_{y \in \mathcal{Y}} (c(x, y) - c(x, y) + f(x)) \end{aligned}$$

3. De même.

4. On a $f^{c\bar{c}} \geq f \Rightarrow f^{ccc} \leq f^c$. Avec $g = f^c$, on a $f^{ccc} \geq f^c$.

■

4.4 Quelques Cas particuliers

4.4.1 Cas Euclidien Quadratique

On veut ici calculer :

$$\min_{X \sim \alpha, Y \sim \beta} \mathbb{E} (\|X - Y\|^2) = K - 2 \max_{X \sim \alpha, Y \sim \beta} \mathbb{E} (\langle X, Y \rangle)$$

où K est une constante ne dépendant que de α et β . On va donc vérifier qu'écrire φ sous la forme $(\alpha, \nabla \varphi \sharp \alpha)$ fonctionne, c'est-à-dire redémontrer le théorème de Brenier :

Preuve du théorème de Brenier. On prend ici $c(x, y) = -\langle x, y \rangle$, qui est symétrique, on obtient que :

$$f^c(y) = -\sup_x \langle x, y \rangle + f(x) = -(-f)^*(y)$$

pour \cdot^* la transformation de Legendre-Fenchel. Puisqu'on sait que $(-f)^*$ est convexe, f^c est concave.

Si π est optimal pour L_c et f est optimal pour le dual, alors :

$$\text{supp}(\pi) \subseteq \{(x, y) \mid f^{cc}(x) + f^c(y) = -\langle x, y \rangle\}$$

En notant $\varphi = -f^{cc}$, φ est convexe et donc :

$$\varphi^*(y) = \sup_x \langle x, y \rangle - \varphi(x) = -f^c(y)$$

On a donc :

$$\text{supp}(\pi) \subseteq \underbrace{\{(x, y) \mid \varphi(x) + \varphi^*(y) = \langle x, y \rangle\}}_{\text{Sous-différentielle } \partial \varphi(x)}$$

Si φ est différentiable :

$$\text{supp}(\pi) \subseteq \{(x, \nabla \varphi(x))\}$$

Puisque φ est convexe, φ est différentiable presque partout pour la mesure de Lebesgue, donc si α est absolument continue par rapport à la mesure de Lebesgue, φ est aussi différentiable presque partout pour α .

■

4.4.2 Cas Semi-discret

On suppose ici α absolument continue et $\beta = \sum_{j=1}^m b_j \delta_{y_j}$. On a :

$$\begin{aligned} L_c(\alpha, \beta) &= \max_{f, g \in \mathcal{C}(\mathcal{X}) \times \mathcal{C}(\mathcal{Y}), f \oplus g \leq c} \int f d\alpha + \int g d\beta \\ &= \max_{f \oplus g \leq c} \int f d\alpha + \sum_{j=1}^m b_j g(y_j) \end{aligned}$$

Avec $\varphi_v(x) = \min_j c(x, y_j) - v_j$, on peut montrer que :

$$\begin{aligned} L_c(\alpha, \beta) &= \max_{v \in (\mathbb{R}^d)^m} \int \varphi_v d\alpha + \sum_{j=1}^m b_j v_j \\ &= \max_v \int \min_j (c(x, y_j) - v_j) d\alpha + \sum_{j=1}^m b_j v_j \end{aligned}$$

Si on considère les cellules de Laguerre :

$$L_j(v) = \{x \in \mathcal{X} \mid \forall j' \neq j, c(x, y_j) - v_j \leq c(x, y_{j'}) - v_{j'}\}$$

On obtient :

$$L_c(\alpha, \beta) = \max_v \sum_j \int_{L_j(v)} (c(x, y_j) - v_j) d\alpha + \langle b, v \rangle$$

4.4.3 Distance 1-Wasserstein

On se place dans le cas $c(x, y) = d(x, y)$ sur $\mathcal{X} = \mathcal{Y}$.

- Proposition 4.5**
1. f est c - concave si et seulement si f est δ -lipschitzienne pour $\delta \leq 1$.
 2. Si $\text{Lip}(f) \leq 1$, alors $f^c = -f^0$

Proposition 4.6 Sous les hypothèses ci-dessus :

$$W_1(\alpha, \beta) = \max_{\varphi, \text{Lip}(\varphi) \leq 1} \int \varphi d(\alpha - \beta)$$

R Dans le cas discret, $\alpha - \beta = \sum m_k \delta_{z_k}$ avec $\sum m_k = 0$. On a donc :

$$W_1(\alpha, \beta) = \max_{u_k} \left\{ \sum_k u_k m_k \mid \forall k, l, |u_k - u_l| \leq d(z_k, z_l) \right\}$$

R Si on est aussi dans le cas euclidien, la condition lipschitzienne globale peut se remplacer par :

$$\|\nabla \varphi\|_\infty \leq 1$$

5 Transport Optimal Tranché

5.1 Définition et propriétés

Définition 5.1 Given $u \in \mathbb{R}^d$, l'opérateur de tranchage (ou *slicing*) basé sur u est défini par :

$$p_u : x \in \mathbb{R}^d = \langle x, u \rangle$$

On va généraliser cette opération sur les mesures grâce à l'opérateur de poussage \sharp : Si $X \sim \mu$, alors $\langle u, X \rangle \sim p_u \sharp \mu$. Dans la suite on note P_u l'application de projection orthogonale sur u .

Définition 5.2 La distance de Wasserstein tranchée par c W_c entre μ et ν est la distance 1-dimensionnelle de Wasserstein basée sur $c : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}_+$ continue est :

$$S W_p(\mu, \nu) = \mathbb{E}_{\theta \sim \mathcal{U}_{\mathbb{S}^{d-1}}} [W(p_\theta \sharp \mu, p_\theta \sharp \nu)]$$

Démonstration. C'est bien une distance, tkt. ■

Proposition 5.1 Pour toutes deux distributions μ, ν sur \mathbb{R}^d :

$$S W_p^p(\mu, \nu) \leq C_{d,p} W_p^p(\mu, \nu)$$

où :

$$C_{d,p} = \frac{1}{d} \int_{\mathbb{S}^{d-1}} \|\theta\|_p^p d\mathcal{U}_{\mathbb{S}^{d-1}}(\theta)$$

5.2 En pratique

On a l'approximation de Monte-Carlo suivante (puisque l'espérance sur la sphère n'est pas calculable en général) :

$$S W_p^p(\mu, \nu) \simeq \frac{1}{K} \sum_{j=1}^K W_p(p_{\theta_j} \sharp \mu, p_{\theta_j} \sharp \nu)^p$$

6 Modèles de Flot et Diffusion

Dans cette section, on s'intéresse à l'espace \mathbb{W}_p des mesures de probabilités sur \mathbb{R}^d muni de la distance de p -Wasserstein.

6.1 Transport optimal dynamique

Dans la suite, $c(x, y) = \|x - y\|^2$. On s'intéresse d'abord aux géodésiques sur cet espace, et à ce qu'elles nous apprennent en apprentissage.

Si on se donne α, β deux mesures de probabilités avec α à densité, et T une application optimale entre α et β , on définit μ_t la distribution de $X_t = (1-t)X_0 + tT(X_0)$ avec $X_0 \sim \alpha$. L'application $t \mapsto \mu_t$ est donc une géodésique dans \mathbb{W}_2 .

Définition 6.1 On définit $v_t(x) = (T - \text{Id}) \circ T_t^{-1}(x)$, de sorte que $v_t \circ T_t(x) = T(x) - x$ est une constante. C'est le champ de vitesse constant sur les chemins de x à $T(x)$.

On a alors :

$$\int_0^1 \int \|v_t(x)\|^2 d\mu_t dt = \int_0^1 \int \|v_t \circ T_t(x)\|^2 d\alpha dt = \int_0^1 \int \|T(x) - x\|^2 d\alpha dt = \int \|T(x) - x\|^2 d\alpha = W_2(\alpha, \beta)$$

Définition 6.2 L'ensemble des chemins avec vitesses entre α et β deux mesures de probabilités est :

$$V(\alpha, \beta) = \{(\mu_t, v_t) \mid \mu_0 = \alpha, \mu_1 = \beta\}$$

où, pour tout t , $\mu_t \in \mathcal{P}(\mathbb{R}^d)$ et où $v : [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ est un champ de vitesses et où la paire (μ_t, v_t) vérifie l'équation de continuité (CE).

Proposition 6.1 Si $T = \nabla \varphi$ avec φ convexe, alors T est monotone et pour tout t , T_t est injective.

Définition 6.3 La paire (μ_t, v_t) satisfait l'équation de continuité si :

$$\frac{d\mu_t}{dt} + \div(\mu_t v_t) = 0 \quad (\text{CE})$$

où l'égalité est entendue au sens des distributions.

Il reste donc à vérifier que $\mu_t = T_t \sharp \alpha$ et $v_t = (T - \text{Id}) \circ T_t^{-1}(x)$ vérifient l'équation de continuité. On se donne ψ à support compact sur $]0, 1[\times \mathbb{R}^d$ et on a :

$$\begin{aligned} \int_0^1 \int \frac{d\psi}{dt} d\mu_t dt &= \int_0^1 \int \frac{d\psi_t}{dt}(T_t(x)) d\alpha dt \\ \int_0^1 \int_{\mathbb{R}^d} \langle \nabla_x \psi, v_t(x) \rangle d\mu_t dt &= \int_0^1 \int_{\mathbb{R}^d} \langle \nabla_x \psi \circ T_t(x), T(x) - x \rangle d\alpha dt \end{aligned}$$

Ainsi :

$$\begin{aligned} \int_0^1 \int_{\mathbb{R}^d} \left(\frac{d\psi_t}{dt} \circ T_t(x) + \langle \nabla_x \psi, v_t(x) \rangle \right) d\mu_t dt &= \int_0^1 \int_{\mathbb{R}^d} \underbrace{\left(\frac{d\psi_t}{dt} \circ T_t(x) + \langle \nabla_x \psi \circ T_t(x), T(x) - x \rangle \right)}_{= \frac{d}{dt}(\psi(t, T(x)))} d\alpha dt \end{aligned}$$

Finalement :

$$\int_0^1 \int_{\mathbb{R}^d} \left(\frac{d\psi_t}{dt} \circ T_t(x) + \langle \nabla_x \psi, v_t(x) \rangle \right) d\mu_t dt = \int_{\mathbb{R}^d} \underbrace{(\psi(1, T(1, x)) - \psi(0, T(0, x)))}_{=0} d\alpha$$

On vérifie donc bien que :

Proposition 6.2

$$W_2^2(\alpha, \beta) \geq \inf_{V(\alpha, \beta)} \int_0^1 \int \|v_t(x)\|^2 d\mu_t dt$$

On rappelle que le flot φ de v est défini par $\frac{d\varphi_t(x)}{dt} = v(t, \varphi_t(x))$ et $\varphi_0(x) = x$.

Avec la définition de v_t ci-dessus, on voit que T_t est le flot de v_t .

Théorème 6.1 Si v_t est uniformément borné et Lipschitz en x (uniformément en t), si φ_t est son flot et si de plus α est absolument continue par rapport à la mesure de Lebesgue, alors, $\rho_t = \varphi_t \sharp \alpha$ est l'unique solution de (CE) avec la condition initiale $\rho_0 = \alpha$.

On obtient donc le Théorème suivant :

Théorème 6.2 — Bénamou-Brenier On a :

$$W_2^2(\alpha, \beta) = \min_{V(\alpha, \beta)} \int_0^1 \int \|\mathbf{v}_t\|^2 d\mu_t dt$$

la solution étant unique et donnée par l'interpolation de McCann et sa vitesse correspondante \mathbf{v}_t .

Démonstration. Utilisant l'équation de la Proposition 6.2 on a déjà une inégalité. En utilisant le Théorème 6.1 ci-dessus, on obtient :

$$\begin{aligned} \int_0^1 \int_{\mathbb{R}^d} \|\mathbf{v}_t(x)\|^2 d\mu_t dt &= \int_0^1 \int_{\mathbb{R}^d} \|\mathbf{v}_t \circ \varphi_t(x)\|^2 d\alpha dt \\ &\stackrel{Fubini}{=} \int_{\mathbb{R}^d} \int_0^1 \|\mathbf{v}_t \circ \varphi_t(x)\|^2 dt d\alpha \\ &\stackrel{Jensen}{\geq} \int_{\mathbb{R}^d} \left\| \int_0^1 \underbrace{\mathbf{v}_t \circ \varphi_t(x)}_{\frac{d\varphi_t}{dt}(x)} dt \right\|^2 d\alpha \\ &= \int_{\mathbb{R}^d} \|\varphi(1, x) - x\|^2 d\alpha \\ &\stackrel{\varphi_1 \sharp \alpha = \beta}{\geq} W_2^2(\alpha, \beta) \end{aligned}$$

Pour l'unicité de la solution, on se donne deux solutions et on introduit leur moyenne, l'inégalité de Cauchy-Schwarz (et son cas d'égalité) nous permet de conclure la preuve. ■

6.2 Couplage de Flot

7 Barycentres et Lois Multimarginales

8 Barycentre de Sinkhorn